

SID Primavera 2026

Práctica 3/3 (Laboratorio)

**Daiwei Chen
Jun Zhe Xia
Wei Wu**

**UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH**

Facultat d'Informàtica de Barcelona



Índice

1. Análisis de experimento Base.....	3
1.1 Elección de parámetros.....	3
1.2 Análisis de recompensa individual y colectiva.....	4
1.3 Análisis de la estabilidad.....	6
1.4 Análisis del efecto de la no estacionariedad multi- agente sobre IQL.....	7
1.5 Análisis de comportamiento entre concepto de solución Nash y Pareto.....	9
1.6 Análisis de las situaciones más adecuadas para Nash y Pareto.....	10
1.7 Análisis de la coordinación y recompensa entre Nash y Pareto.....	11
1.8 Comparación entre algoritmo base y modificación con penalización por truncamiento.....	12
1.9 Análisis de la generalización a mapas no vistos.....	14
1.10 Comparación entre algoritmo base y Decaimiento Polinomial.....	18

1. Análisis de experimento Base

Para evaluar el rendimiento de los algoritmos de aprendizaje multiagente, se ha ejecutado un conjunto de pruebas en entornos de observabilidad parcial (POGEMA) con dos agentes. Se ha comparado el algoritmo Independent Q-Learning (IQL) frente a Joint Action Learning with Game Theory (JAL-GT) utilizando tres conceptos de solución distintos: Equilibrio de Nash, Óptimo de Pareto y Minimax.

Las pruebas se han realizado variando el tamaño del mapa (4x4, 6x6 y 10x10) y la densidad de obstáculos (0.1 y 0.3) para observar cómo el espacio y los aspectos que pueden afectar a la coordinación.

1.1 Elección de parámetros

- Configuración del entorno (Mapas y Densidad)

Los tamaños de mapa seleccionados son 4x4, 6x6, 8x8. Los mapas pequeños (4x4, 6x6), fuerzan una alta tasa de interacción y conflicto, poniendo a prueba la capacidad de coordinación. El mapa de 10x10 sirve para observar cómo se comportan los algoritmos cuando el problema se asemeja más a un entorno de agente único.

Las densidades de obstáculos elegidas son 0.1 y 0.3. Una densidad baja (0.1) permite evaluar la capacidad base de navegación hacia el objetivo con trayectorias relativamente directas. La densidad alta (0.3) genera pasillos estrechos, obligando a los agentes a negociar el paso y poniendo a prueba los algoritmos como IQL, Minimax, bienestar...

- Parámetros de Aprendizaje (Gamma y Epsilon)

Los factores de descuento elegidos son 0.995 y 0.95. Se compara un enfoque con una visión muy a largo instante (0.995 es ideal para propagar recompensas en largo plazo) frente a uno poco más corto (0.95). Este permite observar si descontar la recompensa del futuro más rápido acelera la convergencia en mapas pequeños a costa de fallar en los grandes.

En cuanto al factor de exploración, se compara una estrategia de exploración tradicional más amplia (de 1.0 a 0.1), frente a una estrategia más agresiva orientada a una explotación temprana (de 0.5 a 0.01). Se consideran estas dos configuraciones para observar el trade-off entre la capacidad de evitar óptimos locales y la convergencia hacia una política estable, y para observar los comportamientos de diferentes preferencias en un entorno multiagente.

Tomamos 200 epochs para cada combinación de los parámetros y algoritmos para obtener mejores resultados del entrenamiento, evitando al mismo tiempo que los experimentos tardaran demasiado.

- Extensión del experimento

Se considera como primera extensión de los experimentos base un mecanismo alternativo de decremento de epsilon. Este mecanismo aplica una función polinómica para que el decremento de epsilon sea más rápido al principio y más lento al final. Con esta implementación, se permite mantener un valor alto de epsilon en las primeras fases del entrenamiento y favorecer una buena convergencia posteriormente, utilizando un grado polinómico parametrizable.

La segunda extensión implementada consiste en penalizar la recompensa si, durante un episodio de entrenamiento, no se consigue llegar a un estado final. El valor de esta penalización se puede parametrizar para ajustar el comportamiento del agente e incentivarlo a alcanzar un estado final. En esta práctica se considera un valor de 0.2 para aplicar una penalización moderada.

La tercera extensión del experimento consiste en permitir decidir si, durante la fase de evaluación, se utilizarán mapas no vistos durante la fase de entrenamiento. El objetivo de esta modificación es comprobar si el agente ha aprendido una política suficientemente general o por el contrario, depende demasiado de los mapas utilizados en el entrenamiento.

1.2 Análisis de recompensa individual y colectiva

Planteamiento	Para cada algoritmo se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calcula el valor medio de las recompensas individuales y colectivas obtenidas en todas las configuraciones para comparar el rendimiento global de los algoritmos.
Hipótesis	IQL alcance las mayores recompensas individuales y colectivas, obteniendo el mejor rendimiento global entre los algoritmos considerados.
Método	Tal y como se ha descrito en el planteamiento, para cada algoritmo se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calcula el valor medio de las recompensas individuales y colectivas obtenidas en todas las configuraciones y se comparan los resultados para analizar las diferencias de rendimiento entre algoritmos.




Figura 1

Conclusión

Los resultados muestran que IQL obtiene las mayores recompensas individuales y colectivas entre todos los algoritmos evaluados. La recompensa colectiva media alcanza aproximadamente 0.72, superando claramente a las variantes de JAL-GT consideradas.

En términos de recompensa individual, IQL también presenta el mejor rendimiento global. Sin embargo, existe una diferencia notable entre ambos agentes, ya que el agente 0 obtiene una recompensa considerablemente superior a la del agente 1.

JAL-GT con equilibrio de Nash consigue la segunda mejor recompensa colectiva (≈ 0.39) y muestra una distribución mucho más equilibrada entre ambos agentes, obteniendo recompensas individuales prácticamente iguales. Esto sugiere una mejor coordinación entre los agentes, aunque a costa de una reducción en la recompensa total obtenida.

La variante Pareto presenta un rendimiento inferior a Nash tanto en recompensa individual como colectiva, mientras que Minimax obtiene recompensas negativas para ambos agentes y la peor recompensa colectiva de todos los algoritmos analizados.

En conjunto, los resultados indican que IQL proporciona el mayor rendimiento medio en los escenarios evaluados, mientras que JAL-GT Nash favorece una distribución más equilibrada de las recompensas entre agentes. Por tanto, existe un compromiso entre maximizar la recompensa total y mantener un comportamiento coordinado y equilibrado entre los agentes.

Finalmente, los resultados obtenidos confirman la hipótesis planteada inicialmente. IQL alcanza las mayores recompensas individuales y colectivas entre todos los algoritmos evaluados, mostrando el mejor rendimiento global en los escenarios considerados.

1.3 Análisis de la estabilidad

Planteamiento	Para cada algoritmo se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calcula el valor medio del TD Error obtenido en todas las configuraciones para comparar la estabilidad y la convergencia del entrenamiento entre algoritmos.
Hipótesis	JAL-GT-Nash presenta una convergencia más estable.
Método	Tal y como se ha descrito en el planteamiento, para cada algoritmo se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calcula el valor medio del TD Error obtenido en todas las configuraciones y se comparan los resultados para analizar las diferencias de estabilidad y convergencia entre algoritmos.




Figura 2

Conclusión

Los resultados muestran diferencias claras en la estabilidad del entrenamiento entre los algoritmos analizados. IQL presenta los mayores valores de TD Error y la mayor dispersión, lo que indica una convergencia menos estable y una mayor variabilidad durante el proceso de aprendizaje.

Por el contrario, las variantes de JAL-GT obtienen valores de TD Error inferiores y distribuciones más compactas. Nash y Pareto muestran una convergencia estable, mientras que Minimax presenta la menor variabilidad de todos los algoritmos evaluados.

Estos resultados sugieren que la incorporación explícita de las acciones conjuntas en JAL-GT contribuye a reducir las fluctuaciones durante el aprendizaje y favorece una convergencia más estable.

Finalmente, los resultados obtenidos rechazan la hipótesis planteada inicialmente. JAL-GT_Minimax presenta una convergencia más estable que JAL-GT_Nash.

1.4 Análisis del efecto de la no estacionariedad multi-agente sobre IQL

Planteamiento	Se analiza el efecto de la no estacionariedad multiagente sobre IQL comparando la evolución y la distribución del TD Error frente a las variantes de JAL-GT. Para ello, se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación y se comparan los resultados obtenidos.
Hipótesis	IQL es más afectado por la no estacionariedad multiagente, presentando valores de TD Error más elevados y una mayor variabilidad que las variantes de JAL-GT.
Método	Tal y como se ha descrito en el planteamiento, para cada algoritmo se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calcula el valor medio del TD Error obtenido en todas las configuraciones y se comparan los resultados para analizar las diferencias de estabilidad y convergencia entre algoritmos.

Conclusión

Al analizar los datos, se observa una clara diferencia en la estabilidad del aprendizaje entre IQL y JAL-GT.

En el caso de IQL, el Error de Diferencia Temporal (TD Error) se mantiene persistentemente más alto a lo largo de las épocas. Esto demuestra el problema de la no estacionariedad: dado que cada agente que utiliza IQL ignora la existencia y el proceso de aprendizaje del otro, el entorno resulta ser impredecible desde su

perspectiva individual. Cada actualización en la política de un agente invalida el modelo del entorno que el otro había construido.

Por el contrario, JAL-GT logra estabilizar su TD Error mucho más rápido y con una curva más suave. Al incluir las acciones conjuntas en su tabla Q y modelar el comportamiento del compañero mediante la teoría de juegos, los agentes comprenden las verdaderas dinámicas de transición del entorno, logrando un aprendizaje mucho más robusto frente a colisiones o bloqueos.

Finalmente, los resultados obtenidos confirman la hipótesis planteada inicialmente. Las variantes de JAL-GT presentan una convergencia más estable que IQL, obteniendo valores medios de TD Error inferiores y una menor dispersión en los resultados.




Figura 3: Comparación del TD error entre IQL(izquierda) y JAL-GT(derecha) del mapa 4x4.

1.5 Análisis de comportamiento entre concepto de solución Nash y Pareto

Planteamiento	Se comparan los conceptos de solución Nash y Pareto con el objetivo de analizar las diferencias en el comportamiento que inducen sobre los agentes. Para ello, se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación y se comparan los resultados obtenidos.
Hipótesis	Nash induce comportamientos más coordinados y equilibrados entre los agentes, mientras que Pareto favorecerá soluciones eficientes para el conjunto, aunque con una coordinación menos consistente.
Método	Para cada concepto de solución se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calculan los valores medios de las recompensas individuales y colectivas obtenidas en todas las configuraciones y se comparan los resultados para identificar las diferencias de comportamiento inducidas por cada concepto de solución.

Conclusión

Según los mostrados en la Figura 2, tanto Nash como Pareto presentan procesos de aprendizaje estables, ya que ambos obtienen valores de TD Error relativamente bajos y distribuciones similares.

Sin embargo, según la Figura 1, las recompensas obtenidas muestran diferencias importantes en el comportamiento inducido por cada concepto. Nash alcanza una recompensa colectiva media superior (≈ 0.39 frente a ≈ 0.23) y presenta recompensas individuales prácticamente idénticas para ambos agentes (≈ 0.20 y ≈ 0.19). Estos resultados sugieren que Nash favorece una coordinación equilibrada, en la que ambos agentes contribuyen de forma similar al resultado final.

Por el contrario, Pareto obtiene una recompensa colectiva menor y una distribución menos uniforme de las recompensas individuales (≈ 0.07 y ≈ 0.16). Esto sugiere que, aunque los agentes siguen siendo capaces de alcanzar soluciones eficientes para el conjunto, la coordinación resultante es menos consistente y el beneficio obtenido por cada agente puede diferir de forma más significativa.

En consecuencia, los resultados experimentales indican que Nash induce comportamientos más cooperativos y equilibrados entre los agentes, mientras que Pareto favorece soluciones eficientes desde una perspectiva global, aunque con una coordinación menos efectiva. Por tanto, la hipótesis planteada queda confirmada.

1.6 Análisis de las situaciones más adecuadas para Nash y Pareto

Planteamiento	Se comparan los conceptos de solución Nash y Pareto con el objetivo de identificar en qué situaciones cada uno de ellos parece más adecuado. Para ello, se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación y se analizan las diferencias observadas en las recompensas individuales y colectivas obtenidas.
Hipótesis	Nash induce comportamientos más coordinados y equilibrados entre los agentes, mientras que Pareto favorecerá soluciones eficientes para el conjunto, aunque con una coordinación menos consistente.
Método	Para cada concepto de solución se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calculan los valores medios de las recompensas individuales y colectivas obtenidas en todas las configuraciones y se comparan los resultados para identificar las diferencias de comportamiento inducidas por cada concepto de solución.

Conclusión

Según los resultados obtenidos en la Figura 1, Nash obtiene mayores recompensas individuales y colectivas que Pareto, además de una distribución más equilibrada entre ambos agentes. Esto sugiere que Nash resulta más adecuado en situaciones donde la coordinación y el reparto equilibrado de beneficios entre agentes son aspectos importantes.

Por el contrario, Pareto obtiene recompensas colectivas inferiores y una distribución menos uniforme de las recompensas individuales. Sin embargo, sigue siendo capaz de encontrar soluciones eficientes para el conjunto de agentes. Por ello, Pareto parece más adecuado en situaciones donde el objetivo principal sea alcanzar soluciones globalmente eficientes, aunque las ganancias obtenidas por cada agente no sean necesariamente iguales.

En consecuencia, los resultados experimentales indican que Nash es la alternativa más adecuada para entornos cooperativos donde se busca una coordinación equilibrada, mientras que Pareto puede resultar útil cuando se prioriza la eficiencia global del sistema sobre la igualdad en la distribución de las recompensas. Por tanto, la hipótesis planteada queda confirmada.

1.7 Análisis de la coordinación y recompensa entre Nash y Pareto

Planteamiento	Se comparan los conceptos de solución Nash y Pareto con el objetivo de analizar cómo afectan a la coordinación entre agentes y a las recompensas obtenidas. Para ello, se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación y se comparan los resultados obtenidos.
Hipótesis	Nash favorece una coordinación más efectiva entre los agentes y obtiene recompensas individuales y colectivas superiores a las de Pareto.
Método	Para cada concepto de solución se ejecutan todas las combinaciones posibles de parámetros consideradas en la experimentación. Posteriormente, se calculan los valores medios de las recompensas individuales y colectivas obtenidas en todas las configuraciones y se comparan los resultados para analizar las diferencias de coordinación y rendimiento entre Nash y Pareto.

Conclusión

Según los mostrados en la Figura 1, Nash y Pareto producen diferencias apreciables tanto en la coordinación entre agentes como en las recompensas obtenidas.

Nash alcanza una recompensa colectiva media superior (≈ 0.39) y presenta recompensas individuales prácticamente idénticas para ambos agentes (≈ 0.20 y ≈ 0.19). Estos resultados indican un elevado nivel de coordinación, ya que ambos agentes contribuyen de manera equilibrada al resultado conjunto y obtienen beneficios similares.

Por el contrario, Pareto obtiene una recompensa colectiva menor (≈ 0.23) y muestra una diferencia más marcada entre las recompensas individuales (≈ 0.07 y ≈ 0.16). Aunque los agentes siguen siendo capaces de alcanzar soluciones beneficiosas para el conjunto, la coordinación observada es menos consistente y el reparto de recompensas resulta menos equilibrado.

Por tanto, los resultados experimentales muestran que la elección del concepto de solución influye directamente tanto en la coordinación como en las recompensas obtenidas. En los escenarios evaluados, Nash favorece una coordinación más efectiva y se traduce en mayores recompensas individuales y colectivas que Pareto. En consecuencia, la hipótesis planteada queda confirmada.

1.8 Comparación entre algoritmo base y modificación con penalización por truncamiento

Planteamiento	Se introduce una penalización de 0.2 a los agentes si el episodio finaliza por límite de pasos (truncado) en lugar de por llegar a un estado final.
Hipótesis	Como hipótesis, sugiere que penalizar las acciones redundantes ayudaría a adquirir una política más efectiva en cuanto al reducir el número de pasos de forma más rápida, mejorando la eficiencia general de la resolución.
Método	Se modificó la función de recompensa del entorno para añadir una penalización numérica al agente si el episodio terminaba por superar el número máximo de pasos permitidos (truncamiento) en lugar de finalizar por alcanzar el objetivo.




Figura 4




Figura 5




Figura 6




Figura 7

Conclusión

Contrario a la hipótesis planteada, los resultados muestran una disminución generalizada del rendimiento en todas las configuraciones analizadas. El caso más acusado se observa en JAL-GT Minimax, donde la recompensa colectiva experimenta una caída significativa, acompañada de un incremento del error TD.

La introducción de una penalización adicional de -0.2 en los episodios que no alcanzan el estado objetivo reduce las recompensas individuales y colectivas de todos los algoritmos. Asimismo, el aumento observado en el error TD sugiere que la nueva señal de recompensa dificulta la estimación de los valores esperados y genera una mayor variabilidad durante el proceso de aprendizaje.

En conclusión, la penalización adicional aplicada a los episodios truncados no mejora el rendimiento global y, en cambio, incrementa la dificultad del proceso de aprendizaje, así pues, rechazamos la hipótesis.

1.9 Análisis de la generalización a mapas no vistos

Planteamiento	El objetivo de este análisis es evaluar la capacidad de generalización de los agentes una vez finalizado el entrenamiento. Para ello, los modelos entrenados en un conjunto de mapas son evaluados en mapas no vistos previamente, con el fin de determinar si las políticas aprendidas son capaces de adaptarse a nuevas configuraciones del entorno. Se comparan tanto las recompensas individuales de cada
---------------	---

	agente como la recompensa colectiva del sistema multiagente. Además, se analiza el error TD medio (Temporal Difference Error) para estudiar si las diferencias observadas en el rendimiento están relacionadas con cambios en la calidad de las estimaciones de valor.
Hipótesis	Todos los algoritmos experimenten una reducción de rendimiento al enfrentarse a mapas no vistos
Método	Se generan de forma aleatoria mapas completamente diferentes respecto a la fase del entrenamiento para la fase de la evaluación. Para evaluar la capacidad de generalización, se compararon dos conjuntos de resultados obtenidos en mapas utilizados durante el entrenamiento y el contrario.



Figura 8




Figura 9




Figura 10




Figura 11

Conclusión

En el gráfico de Figura 4, en ambos agentes se observa una reducción significativa de la recompensa al pasar de mapas vistos a mapas no vistos. Entre los algoritmos evaluados, IQL obtiene las mayores recompensas tanto en mapas vistos como en mapas no vistos. Además, conserva una proporción considerable de su rendimiento original, lo que sugiere una mejor capacidad de generalización. Por el contrario, las variantes JAL-GT Nash, JAL-GT Pareto y JAL-GT Welfare presentan una degradación más pronunciada, mientras que JAL-GT Minimax mantiene recompensas negativas en ambos escenarios.

La recompensa colectiva sigue la misma tendencia observada a nivel individual. Todos los algoritmos experimentan una disminución notable de rendimiento en mapas no vistos.

A diferencia de las recompensas, el error TD medio permanece prácticamente constante entre mapas vistos y no vistos para todos los algoritmos. Las variaciones observadas son mínimas y no muestran cambios significativos.

Los resultados confirman la hipótesis inicial de que el rendimiento disminuye al evaluar los agentes en mapas no vistos. Tanto las recompensas individuales como la recompensa colectiva experimentan una reducción significativa respecto a los mapas utilizados durante el entrenamiento.

Entre los métodos evaluados, IQL presenta la mejor capacidad de generalización, ya que obtiene las mayores recompensas en mapas no vistos y conserva una mayor

proporción de su rendimiento original. Las variantes JAL-GT Nash, JAL-GT Pareto y JAL-GT Welfare también logran comportamientos cooperativos razonables, aunque muestran una degradación más acusada al enfrentarse a nuevos entornos. Por su parte, JAL-GT Minimax obtiene los peores resultados, con recompensas negativas tanto en mapas vistos como en mapas no vistos.

Finalmente, la estabilidad observada en el error TD indica que la pérdida de rendimiento no se debe a fallos en el proceso de aprendizaje o convergencia, sino a una capacidad limitada de las políticas aprendidas para transferir eficazmente su comportamiento a configuraciones espaciales no observadas durante el entrenamiento.

1.10 Comparación entre algoritmo base y Decaimiento Polinomial

Planteamiento	En el modelo base, el factor de exploración (Epsilon) decrecía de forma lineal. En esta extensión, se ha aplicado un decaimiento polinómico de grado 2.
Hipótesis	Se esperaba que, al mantener una tasa de exploración alta durante gran parte del entrenamiento y forzar una transición abrupta hacia la explotación al final, los agentes lograrían evadir óptimos locales prematuros y descubrirían políticas conjuntas de mayor eficiencia.
Método	Se sustituyó la estrategia de decaimiento lineal del parámetro de exploración epsilon por una función polinómica de grado 2. A medida que avanza el aprendizaje, el valor de ϵ disminuye progresivamente hasta priorizar la explotación de las políticas aprendidas.



Figura 12




Figura 13



Figura 14




Figura 15

Conclusión

La mejora propuesta consistió en sustituir la estrategia de decay lineal de ϵ por un decay polinómico con el objetivo de mantener la exploración durante una mayor parte del entrenamiento.

Los resultados muestran que ambas estrategias producen rendimientos muy similares en todas las métricas analizadas. Las recompensas individuales y colectivas presentan únicamente variaciones marginales, mientras que el error TD permanece prácticamente constante.

Aunque el decay polinómico está teóricamente mejor adaptado para equilibrar exploración y explotación, en el entorno evaluado no se observa una mejora significativa respecto a la versión base.

En consecuencia, no puede afirmarse que el decay polinómico suponga una mejora clara sobre la configuración original, por lo tanto, rechazamos la hipótesis.